

Global Solution 2026.1

Monitoramento Climático Espacial - MVP

Faculdade: FIAP

Curso: Análise e Desenvolvimento de Sistemas

Disciplina: Global Solution 2026.1

Data de entrega: Junho / 2026

Integrantes

- Cesar Martinho de Azeredo - RM568140
- Carlos Alberto Florindo Costato - RM567005
- Phellype Matheus Giacoia Flaibam Massarente - RM566826

QUERO CONCORRER

1. Introdução

O presente trabalho apresenta um MVP (Minimum Viable Product) de monitoramento climático espacial, desenvolvido como resposta ao desafio proposto pela Global Solution 2026.1 da FIAP: demonstrar como Inteligência Artificial e tecnologias digitais podem transformar a economia espacial e gerar impacto positivo na Terra.

A solução é composta por três pilares integrados:

- Pipeline de Machine Learning - previsão de temperatura horária a partir de dados meteorológicos públicos (Open-Meteo), com seleção automática do melhor modelo por menor erro absoluto médio (MAE).
- Módulo de Visão Computacional - análise de imagens do céu para estimativa de cobertura de nuvens, risco de chuva e emissão de alertas operacionais.
- API REST (FastAPI) - exposição de todos os recursos via endpoints padronizados, viabilizando integração com sistemas externos, dashboards e dispositivos IoT como ESP32.

Um portal Streamlit centraliza a demonstração em uma interface autocontida, com roteiro guiado, exemplos sintéticos embutidos e gerador de PDF de entrega acadêmica.

2.1 Arquitetura e decisões de projeto

Componente	Tecnologia
Linguagem	Python 3.10+
ML	scikit-learn (LinearRegression, RandomForestRegressor)
Visão Computacional	OpenCV (BGR->Gray/HSV, Canny)
API	FastAPI + Uvicorn
Dashboard	Streamlit
Geração de PDF	fpdf2
Evidências automatizadas	Playwright (Chromium headless)
Dados	pandas, numpy, joblib

2.2 Pipeline de Machine Learning (src/ml/train_baseline.py)

Ingestão de dados horários via Open-Meteo com fallback sintético em caso de indisponibilidade. Criação de features temporais (hora, dia da semana, mês). Split temporal 80/20 para evitar vazamento de dados. Treino simultâneo de LinearRegression e RandomForestRegressor. Seleção automática do modelo com menor MAE no conjunto de teste. Persistência do modelo vencedor, dataset processado, previsões, leaderboard e métricas em data/processed/.

2.3 Visão Computacional (src/vision/analyze_image.py)

Conversão de imagem para espaços BGR->Gray e BGR->HSV. Extração de quatro atributos: brilho médio, desvio padrão (contraste), saturação média e densidade de bordas via algoritmo de Canny. Combinação linear ponderada gera dois scores normalizados (0-100):

- cloudiness_score -> classifica condição: clear / partly_cloudy / overcast
- rain_risk_score -> classifica alerta: low / moderate / high

Cada análise é registrada em histórico CSV e exibida como gráfico temporal no dashboard.

2.4 API REST (src/api/main.py)

Endpoint	Método	Descrição
/health	GET	Saúde do serviço
/train	POST	Dispara pipeline ML completo
/predict	GET	Última previsão com modelo ativo
/vision/analyze	POST	Analisa imagem (multipart/form-data)
/vision/history	GET	Histórico de análises de visão
/report/summary	GET	Relatório consolidado para a banca

2.5 Dashboard e automação


FIAP . Global Solution 2026.1 . Análise e Desenvolvimento de Sistemas

Pagina 2

- Portal Streamlit com tema dark espacial, 6 abas sequenciais numeradas e tooltips explicativos em cada ação interativa.
- Aba 03 . Visão Computacional: gerador de imagens sintéticas embutido (4 cenários), eliminando dependência de upload externo durante a apresentação.
- Aba 06 . PDF de Entrega: formulário com nome dos integrantes, flag *QUERO CONCORRER*, link do vídeo e textos das seções - gera o PDF acadêmico estruturado em um clique.
- scripts/run_demo_stack.sh - sobe API + Dashboard com um único comando.
- scripts/smoke_demo.sh - valida endpoints antes de iniciar a gravação.
- scripts/capture_evidencias.py - captura automatizada de 14 screenshots via Playwright (Chromium headless) e geração deste documento.

3. Evidências Visuais

3.1 Tela inicial - hero e KPIs



Tela inicial do portal com hero, KPIs e pilulas de status

3.2 Aba 01 . Visão Geral - roteiro e validação da stack

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 2

Status: Ready Modelo ativo: LinearRegre... MAE: 0.305 Análises de visão: 2

01 - Visão Geral 02 - ML & Predições 03 - Visão Computacional 04 - API & Stack 05 - Relatório 06 - PDF de Entrega

1 Roteiro de apresentação

FIAP TUTORIAL - 0:00 - 0:40 - ABERTURA

Esta aba é a tela inicial do portal. Use-a para abrir o vídeo apresentando o contexto e mostrando que tudo está saudável.

- Aponte para o *hero* no topo: título, KPIs e pículas de status (pipeline, API, modelo, MAE, visão).
- Diga em uma frase o que o MVP entrega (ML + Visão + API consolidada).
- Mostre as *abas 01 a 05* e explique que cada uma corresponde a uma etapa da demo.
- Clique em *Checar serviços agora* para validar API e Dashboard ao vivo — mostre os 3 status verdes.
- Quando terminar, avance para a aba 02 - *ML & Predições*.

Sequência sugerida (~5 min):

- Contexto e arquitetura da solução
- Treino baseline e comparativo de modelos

Validação da stack

Checar serviços agora

Aba 01 com roteiro de apresentacao e atalhos

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 2

Status: Ready Modelo ativo: LinearRegre... MAE: 0.305 Análises de visão: 2

01 - Visão Geral 02 - ML & Predições 03 - Visão Computacional 04 - API & Stack 05 - Relatório 06 - PDF de Entrega

1 Roteiro de apresentação

FIAP TUTORIAL - 0:00 - 0:40 - ABERTURA

Esta aba é a tela inicial do portal. Use-a para abrir o vídeo apresentando o contexto e mostrando que tudo está saudável.

- Aponte para o *hero* no topo: título, KPIs e pículas de status (pipeline, API, modelo, MAE, visão).
- Diga em uma frase o que o MVP entrega (ML + Visão + API consolidada).
- Mostre as *abas 01 a 05* e explique que cada uma corresponde a uma etapa da demo.
- Clique em *Checar serviços agora* para validar API e Dashboard ao vivo — mostre os 3 status verdes.
- Quando terminar, avance para a aba 02 - *ML & Predições*.

Sequência sugerida (~5 min):

Faz uma chamada HTTP para API/health, Dashboard e /report/summary e mostra o status.

Checar serviços agora

Validacao da stack - API e Dashboard com status OK

3.3 Aba 02 . ML & Predições

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 2

Status: Ready Modelo ativo: LinearRegre... MAE: 0.305 Análises de visão: 2

01 - Visão Geral 02 - ML & Predições 03 - Visão Computacional 04 - API & Stack 05 - Relatório 06 - PDF de Entrega

2 Pipeline de Machine Learning

TUTORIAL - 0:40 - 1:50 - ML & PREDIÇÕES

Nesta aba você demonstra o pipeline de ML: ingestão de dados, treino, seleção do melhor modelo por MAE e geração das predições.

- Clique em *Treinar baseline agora* e espere o spinner concluir (segundos).
- Aponte os 3 cards: *Status pipeline*, *Melhor modelo* e *MAE*.
- Mostre o *Dataset processado* à esquerda e as *Predições baseline* à direita.
- Role até o *Comparativo de modelos* e diga, em uma frase, qual modelo venceu e por quê (menor MAE).
- Avance para a aba 03 - Visão Computacional.

Treinar baseline agora

Status pipeline: Ready Melhor modelo: LinearReg... MAE: 0.305

Aba ML antes do treino

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 2

Status: Ready Modelo ativo: LinearRegre... MAE: 0.305 Análises de visão: 2

01 - Visão Geral 02 - ML & Predições 03 - Visão Computacional 04 - API & Stack 05 - Relatório 06 - PDF de Entrega

2 Pipeline de Machine Learning

TUTORIAL - 0:40 - 1:50 - ML & PREDIÇÕES

Nesta aba você demonstra o pipeline de ML: ingestão de dados, treino, seleção do melhor modelo por MAE e geração das predições.

- Clique em *Treinar baseline agora* e espere o spinner concluir (segundos).
- Aponte os 3 cards: *Status pipeline*, *Melhor modelo* e *MAE*.
- Mostre o *Dataset processado* à esquerda e as *Predições baseline* à direita.
- Role até o *Comparativo de modelos* e diga, em uma frase, qual modelo venceu e por quê (menor MAE).
- Avance para a aba 03 - Visão Computacional.


Executa o pipeline: ingestao -> features -> treino LR e RF -> selecao por MAE -> persistencia em disco.

Treinar baseline agora

Modelo salvo em


Status pipeline: Ready Melhor modelo: LinearReg... MAE: 0.305

Aba ML após treino - modelo selecionado: LinearRegression, MAE: 0.3050C



Dataset processado, predições baseline e comparativo de modelos - 70 registros horários

3.4 Aba 03 . Visão Computacional



Aba Visao Computacional - seletor de cenario e botao de exemplo

FIAP . Global Solution 2026.1 . Análise e Desenvolvimento de Sistemas

Aqui você mostra o módulo de visão computacional: enviar uma imagem do céu, ler as métricas e exibir o histórico temporal.

- Clique em *Browse files* e selecione uma imagem do céu (PNG ou JPG).
- Aponte os 3 cards de resultado: *Condição*, *Risco de chuva* e *Alerta*.
- Abra o *JSON* abaixo (1 clique) para mostrar o detalhe bruto da análise.
- Role até o *Histórico de análises* e mostre o gráfico temporal alimentado a cada upload.
- Avance para a aba 04 - *API & Stack*.

Use uma imagem sintética abaixo (sem precisar de upload) ou envie uma própria.

Exemplo embutido (gera imagem sintética)

Cenário de exemplo

Gera uma imagem do céu sintética em memória e roda o pipeline de visão.

Gerar e analisar exemplo

Baixar imagem de exemplo



Cenário sintético: overcast

Condição ⓘ

overc...

Risco de chuva ⓘ

86.44%

Alerta ⓘ

high

{...}

Resultado da análise sintética - condicao, risco de chuva e alerta

Aqui você mostra o módulo de visão computacional: enviar uma imagem do céu, ler as métricas e exibir o histórico temporal.

- Clique em *Browse files* e selecione uma imagem do céu (PNG ou JPG).
- Aponte os 3 cards de resultado: *Condição*, *Risco de chuva* e *Alerta*.
- Abra o *JSON* abaixo (1 clique) para mostrar o detalhe bruto da análise.
- Role até o *Histórico de análises* e mostre o gráfico temporal alimentado a cada upload.
- Avance para a aba 04 - *API & Stack*.

Use uma imagem sintética abaixo (sem precisar de upload) ou envie uma própria.


Exemplo embutido (gera imagem sintética)

Cenário de exemplo

Gera uma imagem do céu sintética em memória e roda o pipeline de visão.

Gerar e analisar exemplo

Baixar imagem de exemplo



Cenário sintético: overcast

Condição ⓘ

overc...

Risco de chuva ⓘ

86.44%

Alerta ⓘ

high

{...}

Histórico temporal de análises - 3 registros acumulados (condição: overcast, alerta: high)

3.5 Aba 04 . API & Stack

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 2

Status: **Ready** Modelo abto: **LinearRegre...** MAE: **0.305** Análises de visão: **2**

01 - visão geral 02 - ML & Predições 03 - visão Computacional **04 - API & Stack** 05 - Relatório 06 - PDF de Entrega

4 API local

3:34C TUTORIAL : 3:20 - 4:10 - API & STACK

Use esta aba para mostrar que toda a inteligência está disponível via API FastAPI, pronta para integração com outros sistemas.

- Leia rapidamente a lista de *endpoints principais* abaixo.
- Clique em *Abrir API docs (Swagger)* para mostrar a documentação interativa em outra aba.
- Volte e clique em *Abrir relatório JSON* para mostrar a saída real do */report/summary*.
- Avance para a aba *05 - Relatório*.

Endpoints principais:

- **GET /health** - saúde do serviço
- **POST /train** - dispara treino e seleção do melhor modelo
- **GET /predict** - última predição com o modelo ativo.

Aba API com lista de endpoints e links para documentação interativa

3.6 Documentação interativa - Swagger UI

GS Climate API 0.1.0 OAS 3.1

/openapi.json

default

GET	/health	Health	⌵
POST	/train	Train	⌵
GET	/predict	Predict Stub	⌵
POST	/vision/analyze	Vision Analyze	⌵
GET	/vision/history	Vision History	⌵
GET	/report/summary	Report Summary	⌵

Schemas

Body_vision_analyze_vision_analyze_post > Expand all object

HTTPValidationError > Expand all object

ValidationError > Expand all object

Swagger UI - documentação automática gerada pelo FastAPI, disponível em `/docs`

3.7 Endpoint /report/summary - saída consolidada

Pretty-print ☐

```
{
  "status": "ready",
  "ml": {
    "model": "LinearRegression",
    "mae": 0.3051833909940192,
    "rows_train": 56,
    "rows_test": 14,
    "dataset_rows": 70,
    "latest_prediction": {
      "timestamp": "2026-06-07 22:00:00",
      "target_real": 14.6,
      "target_pred": 14.909077969791657,
      "vision": {
        "count": 3,
        "avg_cloudiness": 78.2,
        "avg_rain_risk": 77.44,
        "last_condition": "overcast",
        "last_alert": "high"
      }
    }
  }
}
```

FIAP . Global Solution 2026.1 . Analise e Desenvolvimento de Sistemas

Pagina 8

Endpoint `/report/summary` - resposta JSON consolidando status do pipeline ML e módulo de visão

3.8 Aba 05 . Relatório consolidado

GLOBAL SOLUTION 2026.1 - FIAP

Monitoramento Climático Espacial

Pipeline ML + Visão Computacional + API - MVP pronto para apresentação em 5 minutos.

Pipeline: ready API local Modelo: LinearRegression MAE: 0.3051833909940192 Análises de visão: 3

Status: **Ready** Modelo ativo: **LinearRegre...** MAE: **0.305** Análises de visão: **3**

01 - Visão Geral 02 - ML & Predições 03 - Visão Computacional 04 - API & Stack **05 - Relatório** 06 - PDF de Entrega

5 Relatório consolidado

BIF3AC TUTORIAL - 4:10 - 5:00 - FECHAMENTO


Esta é a aba de fechamento. Use-a para entregar o relatório consolidado e citar os próximos passos.

- Mostre o *JSON consolidado* abaixo — status, modelo ativo, métricas e resumo da visão.
- Clique em *Baixar relatório JSON* para evidenciar o entregável.
- Cite os próximos passos: *IoT real com ESP32, dados satelitais adicionais e deploy em cloud*.
- Encerre agradecendo e abrindo para perguntas.

```
{
  "status": "ready"
  "ml": {
    "model": "LinearRegression"
    "mae": 0.3051833909940192
  }
}
```

Aba Relatório - JSON renderizado no dashboard e disponível para download

3.9 Aba 06 . Gerador de PDF de Entrega



Aba PDF - formulário acadêmico com seções pré-preenchidas, flag QUERO CONCORRER e campo para link do vídeo

4. Snapshot do Relatório Consolidado

A seguir, a resposta completa do endpoint GET /report/summary capturada durante a execução do MVP:

```
{
  "status": "ready",
  "ml": {
    "model": "LinearRegression",
    "mae": 0.3051833909940192,
    "rows_train": 56,
    "rows_test": 14
  },
  "dataset_rows": 70,
  "latest_prediction": {
    "timestamp": "2026-06-07 22:00:00",
    "target_real": 14.6,
    "target_pred": 14.909077969791657
  },
  "vision": {
    "count": 3,
    "avg_cloudiness": 78.2,
    "avg_rain_risk": 77.44,
    "last_condition": "overcast",
    "last_alert": "high"
  }
}
```

5. Resultados Esperados

Resultado	Valor obtido
MAE da previsão de temperatura	0,305oC (LinearRegression vencedor)
Modelo treinado e persistido	LinearRegression (selecionado automaticamente)
Registros no dataset	70 observações horárias
Análises de visão acumuladas	3 imagens analisadas (condição: overcast, alerta: high)
Endpoints API funcionais	6 endpoints validados via smoke test
Portal autocontido	Apresentação em 5 minutos sem dependências externas

O MVP demonstra a viabilidade técnica do ciclo completo: ingestão -> ML -> visão -> API -> dashboard, integrável com dispositivos IoT e serviços cloud em etapas futuras.

6. Conclusões

O grupo entregou uma POC funcional que demonstra como IA e tecnologias digitais podem ser aplicadas ao monitoramento climático com dados de origem espacial, gerando impacto direto em decisões operacionais na Terra.

Os três pilares (ML, Visão Computacional e API) foram integrados em um portal autocontido, validado por testes automatizados e documentado com evidências capturadas via Playwright.

Próximos passos planejados:

- Integração com IoT real - ESP32 com sensores ambientais conectados via MQTT.
- Ampliação da base de dados com fontes satelitais adicionais (NASA POWER, Copernicus).
- Deploy em cloud (AWS / GCP) com pipeline de CI/CD e monitoramento de drift do modelo.
- Substituição dos modelos baseline por séries temporais (LSTM / Prophet) para horizontes de previsão mais longos.

A arquitetura modular adotada permite a evolução incremental sem retrabalho dos componentes já validados.

7. Link do Vídeo

(Cole o link após publicar no YouTube não listado)

